论文数据处理主要步骤

1. 数据源:

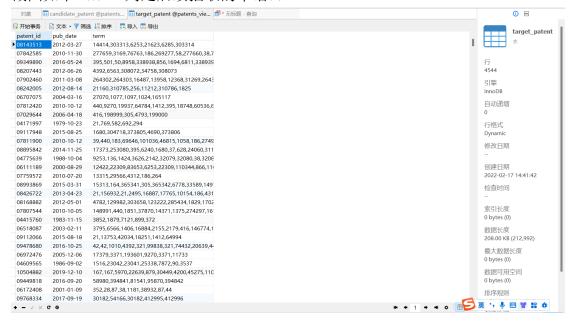
(1) USPTO 下载的 1976-2019 年的专利全文本数据,比如 2004 年数据的下载链接为(其他年份只需修改一下年份即可):

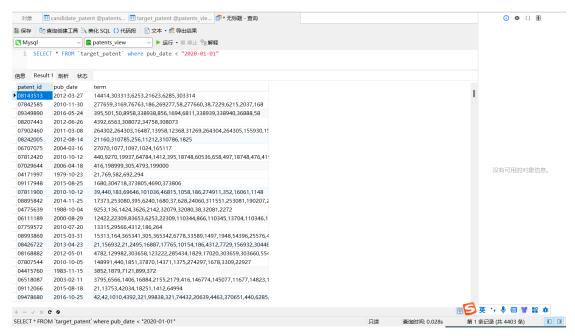
https://bulkdata.uspto.gov/data/patent/grant/redbook/fulltext/2004/

下图是 2010 年 ipg100406.xml 文件的截图,需要在类似这种文件中解析出专利引用关系及全文本内容。

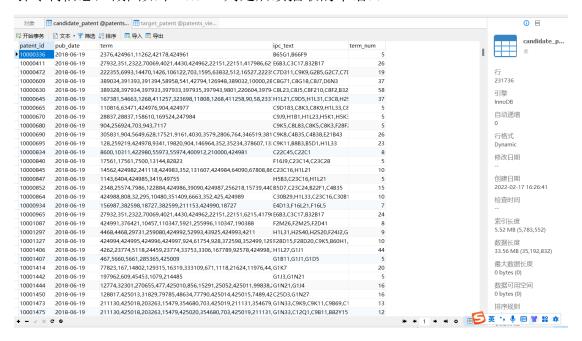
```
| Comparation |
```

(2)从 PatentsView 数据库中筛选 CPC 分类号为 Y02E 10/545 (微晶硅光伏电池)、Y02E 10/546 (多晶硅光伏电池)、Y02E 10/547 (单晶硅光伏电池)和 Y02E 10/548 (非晶硅光伏电池)的专利,专利公开年份限定为 1976-2019 年,所搜集的目标专利类型均为已授权的发明专利。经过筛选后,得到 4403 个目标专利。截图如下 (term 列是后续抽取的术语):





候选专利集既包含目标专利的施引专利信息,也包含被引专利以及被引专利的施引专利信息,截图如下(term 列是后续抽取的术语):



2. 术语抽取

C-Value 抽取术语过程详见代码 C_Values.py 和 extract_term_corenlp.py 文件,主要分为以下几步:读取全文本、切分段落、文本词性标注、抽取候选术语集、计算 C-value 值、术语筛选等。术语抽取后,得到 230696 个专利原始术语文件(一个专利对应一个文件),详见 ./term/extracted_term/文件夹。

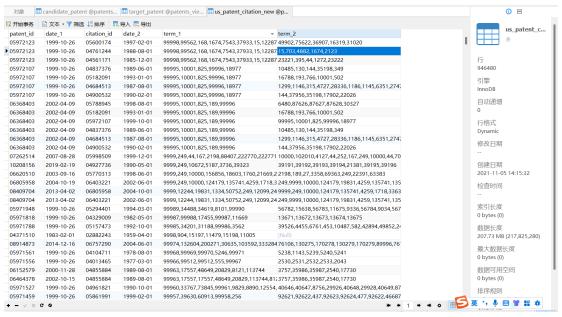
为了剔除一些噪声术语,本文进行了一些操作,详见 ./term/write_term.py 程序。主要操作包括:进行词形还原、剔除包含数字等其他非英语字符的术语、剔除所有单词不超过三个字符的术语、剔除存在单词字符长度超过 45 的术语、剔

除全部单词均为一样的术语、剔除单词存在两个以上横杠的术语等。处理后,得到术语总计 451100 个,详见 ./term/term_dict.txt 文件,并同时将专利对应的术语写入数据库中。

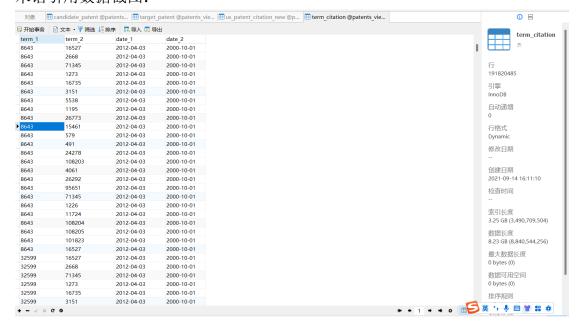
3. 指标计算

(1) 根据专利引用关系,构建术语引用关系,详见 term_citation.py 程序。如: PatA 术语有 T1, T2; PatB 有术语 T3, T4; PatB 引用了 PatA, 那么术语引用就有 T3 引用 T1 和 T2、T4 引用 T1 和 T2 这四种引用关系。(即采用笛卡尔积形式)

专利引用数据截图:



术语引用数据截图:



(2) 计算专利公开 5 年后的影响力指标, 详见 disruption_indicator.py 文件。

- (3) 计算计算基于术语创新和术语复用的四个指标, 详见combination_indicator.py 文件。
- (4) 将上述数据按照 patent_id 整合起来得到最终的特征数据 model_data.xlsx。根据 G. F. Netmet 等和 B. Sun 等的研究,将 1977-1996 年期间公开的 824 个专利作为参加训练模型的数据,这些专利中有 104 个专利被上述两个研究确定为具有重大颠覆的专利,剩余的 720 个专利被确定为非颠覆性专利。

4. 模型训练及预测

详见 model.py 文件。主要步骤:读取 model_data 数据,1977-1996 年期间 824 个专利进行模型训练,绘制 DCA 曲线以确定最优分类阈值。确定分类阈值后,对 1997-2014 年专利进行预测,最后的预测结果 patent_disruption_result.xlsx。程序运行截图如下:

